Report

김준호

Test macro 점수 결과

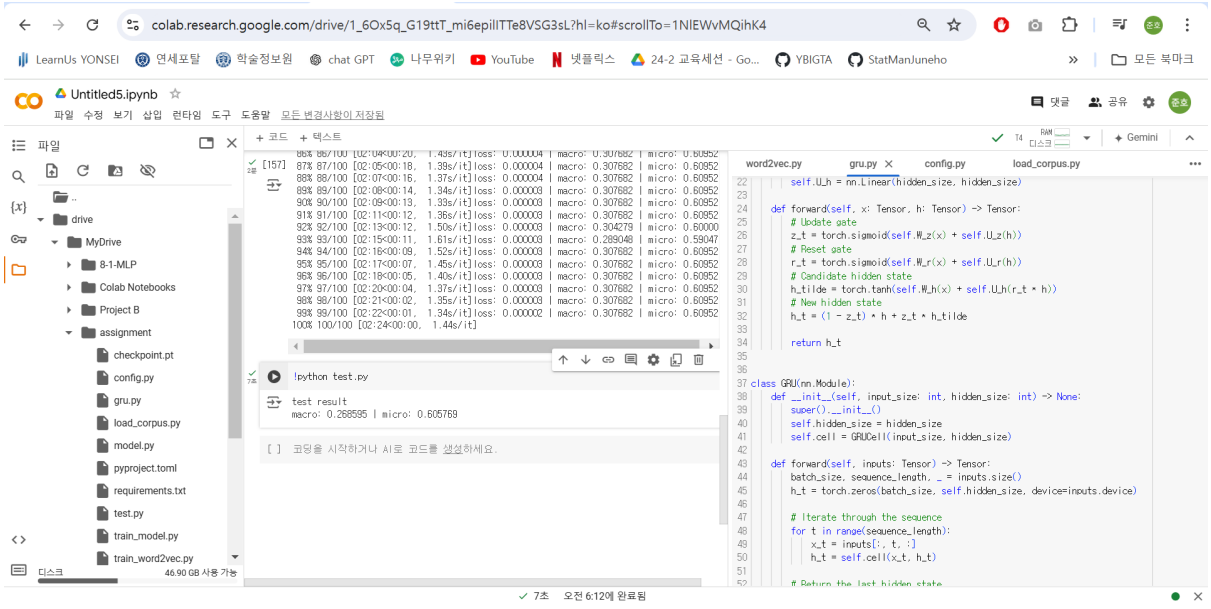

0.268595가 나온 모습이다. 계속 0.25~0.31 사이로만 나오고, 무슨 짓을 해도 0.4이상은 안나온다... 뭐가 문제인지 더 찾아볼 계획이다.

다음은 mypy test 결과이다.

문제없이 잘 완수했다!

코드에 대한 설명

word2vec.py

Word2Vec은 단어 임베딩을 학습하는 데 사용되며, CBOW(Continuous Bag of Words)와 Skip-gram 두 가지 방법을 지원한다.

Word2Vec 클래스

__init__ 메서드:

-vocab_size: 어휘 크기. 사용할 수 있는 고유 단어의 수이다.

-d_model: 임베딩 차원. 각 단어를 표현할 벡터의 길이를 나타낸다.

-window_size: CBOW 및 Skip-gram에서 문맥을 고려할 단어의 수를 정의한다.

-method: "cbow" 또는 "skipgram" 중 하나를 선택하여 학습 방법을 지정한다.

-embeddings: 단어를 벡터로 변환하는 임베딩 레이어이다.

-output_weights: 임베딩 벡터를 다시 어휘 크기로 변환하는 선형 레이어이다.

embeddings_weight 메서드:

-학습된 임베딩의 가중치를 반환한다. 모델이 학습한 단어 임베딩을 외부에서 사용할 수 있도록 역할을 한다..

fit 메서드:

-load_corpus를 기반으로 Word2Vec 모델을 학습한다.

-tokenizer를 사용하여 텍스트 데이터를 토큰화한다.

-CBOW와 Skip-gram 방법에 따라 각각 문맥 단어와 타겟 단어를 정의하고 학습을 진행한다.

-각 에폭 동안 손실을 계산하고 이를 출력하여 학습 과정을 모니터링한다.

_train_cbow 메서드:

-CBOW 방식을 사용하여 학습한다.

-문맥 단어의 평균 임베딩을 통해 타겟 단어를 예측한다.

-손실을 역전파하여 가중치를 업데이트한다.

_train_skipgram 메서드:

-Skip-gram 방식을 사용하여 학습한다.

-타겟 단어의 임베딩을 사용하여 문맥 단어를 예측한다.

-손실을 역전파하여 가중치를 업데이트한다.

load_corpus.py

Word2Vec 모델을 학습시키기 위한 코퍼스를 제공한다. 간단한 예제 문장 리스트를 사용했다. 외부 소스로부터 데이터를 가져온다면 좀 더 제대로 할 수 있겠지만 시간이 너무 오래걸려 포기했다....

load_corpus 함수:

-코퍼스를 문자열 목록으로 반환한다. 임의의 데이터셋을 사용할 수 있도록 설계되어 있다.

gru.py

Gated Recurrent Unit(GRU) 셀과 GRU 네트워크를 PyTorch로 구현한 것이다. GRU는 시퀀스 데이터를 처리하는 데 사용되며 LSTM보다 간단한 구조를 가지고 있다고 한다.

GRUCell 클래스

__init__ 메서드:

-input_size: input의 차원이다.

-hidden_size: GRU의 hidden state 크기이다.

-W_z, U_z: update gate의 가중치이다.

-W_r, U_r: reset gate의 가중치이다.

-W_h, U_h: candidate hidden state의 가중치이다.

forward 메서드:

-입력 x와 이전 hidden state h를 사용하여 현재 hidden state h_t를 계산한다.

-업데이트 게이트 z_t: z_t입력과 이전 은닉 상태를 사용하여 게이트 값을 계산한다.

-리셋 게이트 r_t: r_t 입력과 이전 은닉 상태를 사용하여 게이트 값을 계산한다.

-후보 은닉 상태 (h_t)tilde: 리셋 게이트와 이전 은닉 상태를 활용하여 새로운 후보 은닉 상태를 계산한다.

-새로운 은닉 상태 h_t: 업데이트 게이트를 사용하여 이전 은닉 상태와 후보 은닉 상태를 결합하여 계산한다.

GRU 클래스

__init__ 메서드:

-input_size: 입력 특징의 차원이다.

-hidden_size: GRU의 은닉 상태 크기이다.

-cell: GRUCell 객체로 각 타임 스텝의 은닉 상태를 업데이트한다.

forward 메서드:

-입력 시퀀스를 순회하며 각 타임 스텝에서 GRU 셀을 통해 은닉 상태를 업데이트한다.

-마지막 타임 스텝의 은닉 상태를 반환한다. 이 은닉 상태는 시퀀스의 정보를 집약하여 담고 있다.